AGH UNIVERSITY OF SCIENCE AND TECHNOLOGY

WYDZIAŁ FIZYKI I INFORMATYKI STOSOWANEJ
KIERUNEK STUDIÓW: INFORMATYKA STOSOWANA

METODY INTELIGENCJI OBLICZENIOWEJ

Sprawozdanie

Budowa modelu predykcyjnego dla wskaźnika inflacji

---

zrealizowali
Maciej Müller
Przemysław Ryś
Maksymilian Świątek

Kraków, Czerwiec 2025

1 Cel Projektu

Celem projektu jest budowa modelu predykcyjnego dla wskaźnika inflacji z założeniem, że możemy wykorzystywać wartości wskaźników z poprzednich miesięcy (nie z miesiąca dla którego wyznaczamy wartość wskaźnika).

2 Dane

Dane do analizy pobraliśmy ze strony Głównego Urzędu Statystycznego i wyodrębniliśmy dane, których wartość inflacji w kolejnych miesiącach ma wartości w procentach względem poprzedniego miesiąca (poprzedni miesiąc = 100). Warto zauważyć, że od stycznia 1999 r. wskaźniki cen towarów i usług konsumpcyjnych obliczane są według klasyfikacji COICOP (klasyfikacja spożycia indywidualnego według celu). Zmieniło to sposób obliczania inflacji, niemniej w późniejszych latach kolejne wskaźniki nieznaczenie się różniły.
W danych wykryliśmy outliery tj. wartości, które odbiegały znacząco od reszty. Zamiast usuwać tych danych, zabraliśmy wartości z miesięcy poprzedzających je, aby nie stracić ciągłości w kolejnych miesiącach. Outliery zostały wykryte metodą 3 sigm dla miesięcy:

Luty 1982 r.	$\rightarrow$ wartość: 136.3%
Sierpień 1989 r.	$\rightarrow$ wartość: 139.5%
Wrzesień 1989 r.	$\rightarrow$ wartość: 134.4%
Październik 1989 r.	$\rightarrow$ wartość: 154.8%
Listopad 1989 r.	$\rightarrow$ wartość: 122.4%
Styczeń 1990 r.	$\rightarrow$ wartość: 179.6%
Luty 1990 r.	$\rightarrow$ wartość: 123.8%

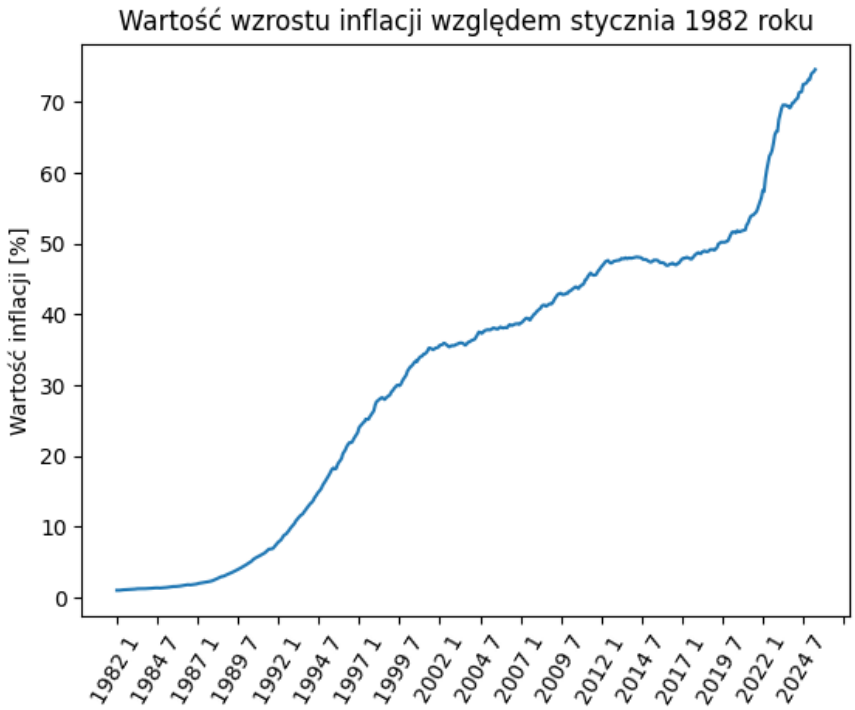

Rys. 1: Wykres obrazujący wzrost procentowy inflacji, względem stycznia 1982 roku.

Zaimplementowaliśmy dwa modele w celu wykonania predykcji na kolejne miesiące. Pierwszym z nich był **LSTM**, drugim natomiast **MLPRegression**, tym samym pokazaliśmy porównanie obu podejść.
W obu przypadkach podzieliliśmy dane na trenujące i testowe w proporcji 80/20 w celu przepadania poprawności uczenia.

3 Model LSTM

LSTM (Long Short-Term Memory) jest rodzajem rekurencyjnej sieci neuronowej (RNN) zaprojektowanej do przetwarzania i prognozowania sekwencji danych w czasie – czyli takich, w których kolejność ma znaczenie, w szczególności dla danych inflacji.

Podział danych

Pierwszą zagwozdką na którą się natknęliśmy, było wybranie danych na których chcieliśmy uczyć model, ponieważ zestawione były na stronie w sposób zależny od poprzednich miesięcy. Drugą był znaczny skok wartości w latach 1989-1992 spowodowany transformacją gospodarczą w Polsce, dlatego też rozważaliśmy, czy by w ogóle nie pominąć tego okresu, gdyż wpłynąłby on negatywnie na zachowanie modelu. By rozwiać te wątpliwości oraz wybrać najlepszą reprezentacje danych wykonaliśmy uczenie na każdym zestawie dla modelu LSTM.

Zestaw 1

Surowe dane, liczone względem poprzedniego miesiąca.

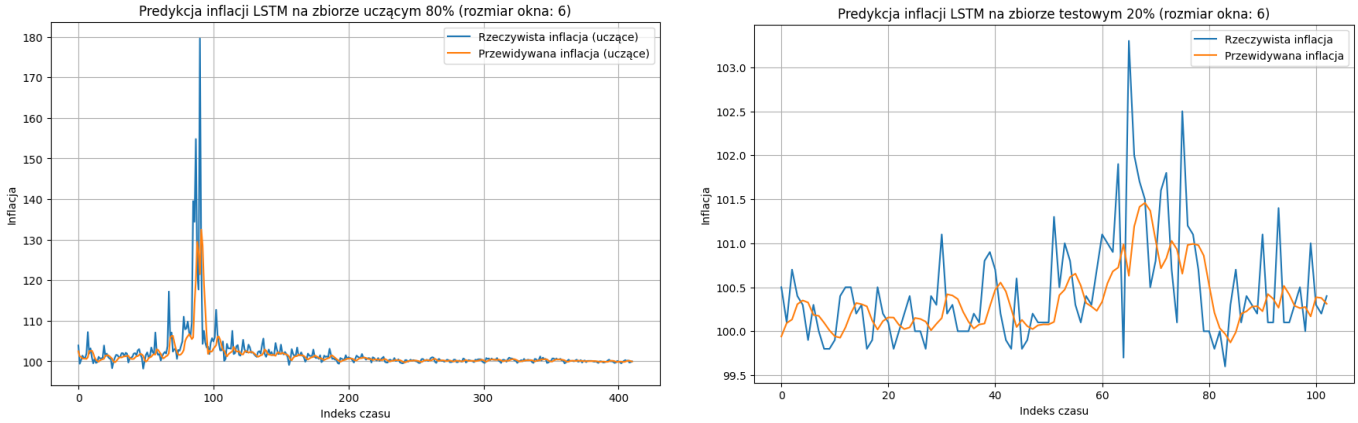

Rys. 2: Predykcja modelu dla danych treningowych oraz testowych dla zestawu 1.

Dane treningowe
RMSE: 1.7636
MAPE: 0.86%

Dane testowe
RMSE: 0.5483
MAPE: 0.39%

Zestaw 2

Surowe dane, liczone względem poprzedniego miesiąca od indeksu 150 (Od czerwca 1994 r.), aby model nie uczył się dla danych zawierających duże wahania.

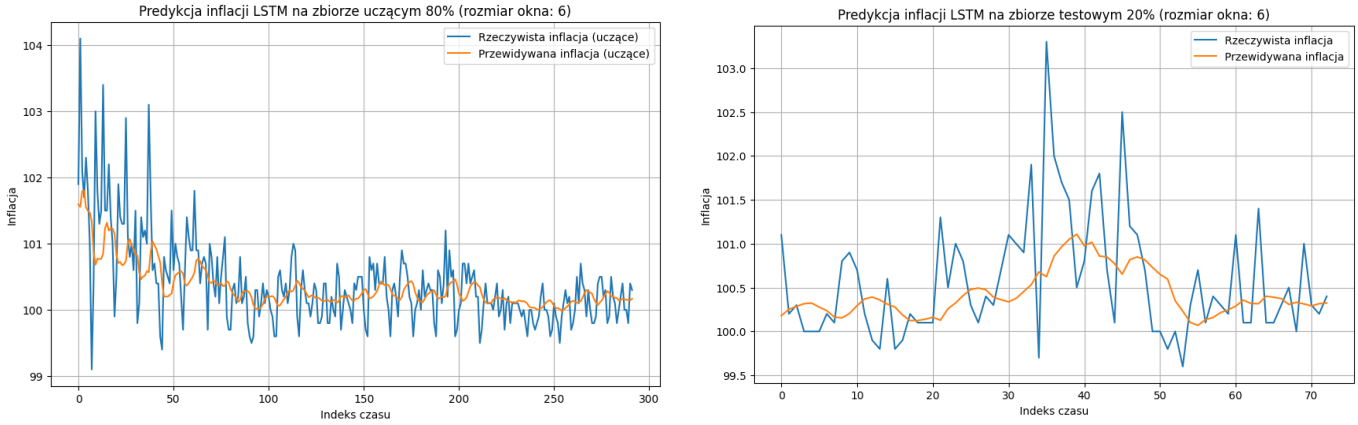

Rys. 3: Predykcja modelu dla danych treningowych oraz testowych dla zestawu 2.

Dane treningowe
RMSE: 0.5676
MAPE: 0.38%

Dane testowe
RMSE: 0.6593
MAPE: 0.46%

Zestaw 3

Dane w skali bezwzględnej w stosunku do 1-ego indeksu danych (styczeń 1982 r. ma wartość 1).

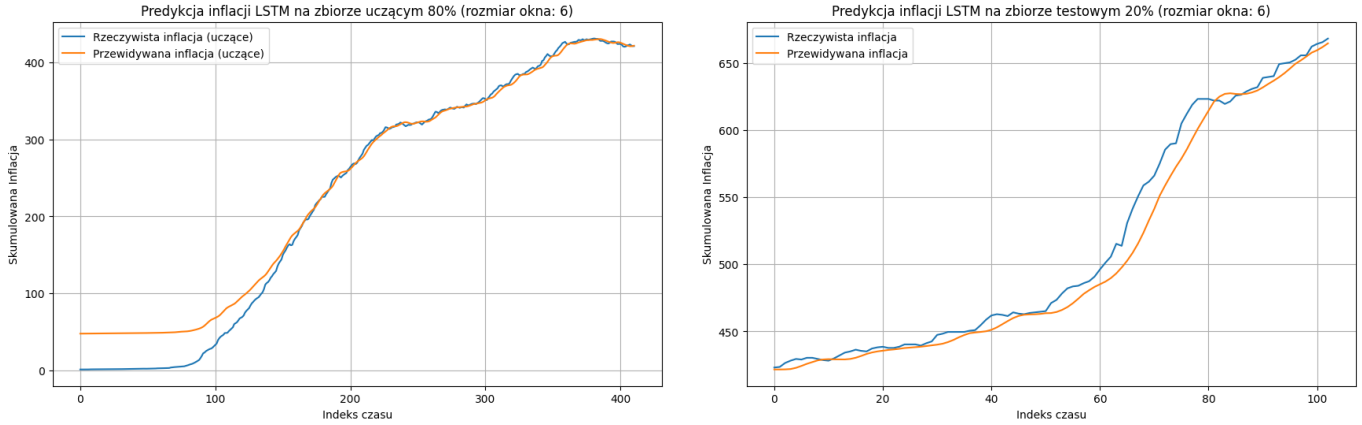

Rys. 4: Predykcja modelu dla danych treningowych oraz testowych dla zestawu 3.

Dane treningowe
RMSE: 23.8000
MAPE: 462.86%

Dane testowe
RMSE: 11.8597
MAPE: 1.53%

Zestaw 4

Dane w skali bezwzględnej w stosunku do 150-ego indeksu danych (czerwiec 1994 r. ma wartość 1).

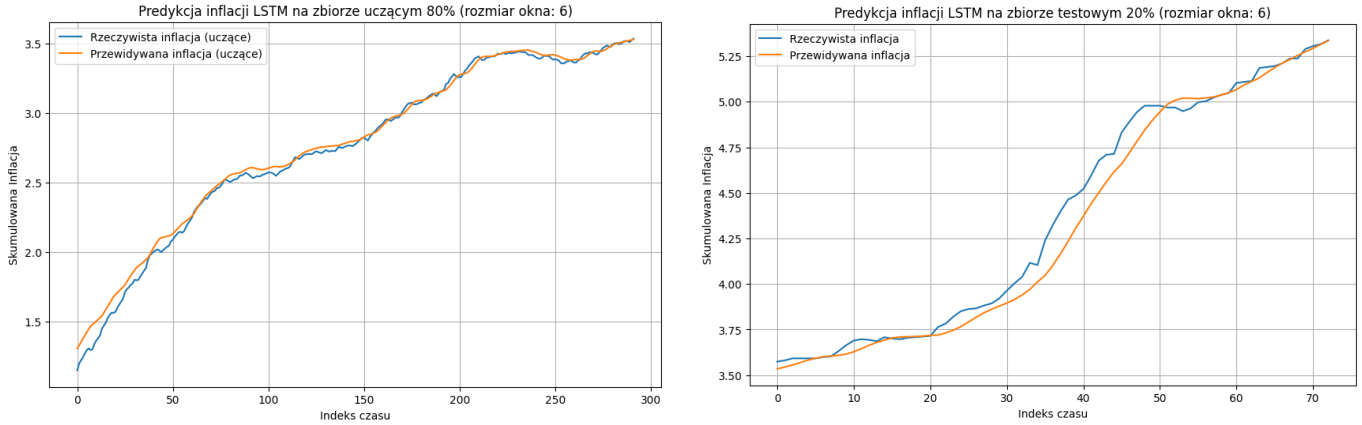

Rys. 5: Predykcja modelu dla danych treningowych oraz testowych dla zestawu 4.

Dane treningowe
RMSE: 0.0479
MAPE: 1.68%

Dane testowe
RMSE: 0.0874
MAPE: 1.37%

Analiza zestawów (postaci) danych

Analizując powyższe podejścia do reprezentacji danych, można zauważyć, że w obu przypadkach, gdy korzystamy z pełnego zakresu danych, otrzymujemy wysokie wartości błędu procentowego MAPE. Ponieważ MAPE nie zależy od skali danych, jest to odpowiednia miara do porównania jakości modeli na czterech różnych zestawach danych, na których przeprowadzono trening.

Porównanie błędów pokazuje, że najbardziej korzystne jest pozostanie przy skali względnej inflacji. Wynika to głównie z faktu, że model stara się wychwycić wzorce w zmianach procentowych, a nie

bezwzględne zmiany wartości. Kiedy tempo wzrostów jest duże, model "nie nadąża"odpowiednio reagować - szybciej rosną dane prawdziwe od przewidzianych. Można to zaobserwować dla danych testowych w przedziale indeksów 60-80 na rysunku 4 oraz w przedziale indeksów 30-50 na rysunku 5.

Z kolei w przypadku danych przedstawiających inflację w skali procentowej względem poprzedniego miesiąca, model nie musi „nadążać” za długoterminowymi trendami w danych rzeczywistych. Jak pokazują wykresy 2 oraz 3 dla danych testowych, rzeczywisty wskaźnik inflacji (krzywa niebieska) często wykazuje zarówno wzrosty, jak i spadki. Oscylacje te wielokrotnie przecinają pomarańczową krzywą reprezentującą prognozowane wartości, co sprawia, że mimo lokalnych odchyleń prognozy modelu są średnio dobrze dopasowane do rzeczywistego przebiegu inflacji.

Intuicyjnie wydawać by się mogło, że lepsze są dane od czerwca 1994 roku, ponieważ pomijamy okres gwałtownej i niestabilnej inflacji związanej z transformacją ustrojową i gospodarczą w Polsce. Niemniej patrząc na przewidywania modelu (krzywa pomarańczowa) na wykresach 2 oraz 3 dla danych testowych, zauważyć można lepsze dopasowanie dla danych, które ten okres uwzględniają, co potwierdzają również statystyki błędów dopasowania. Dzieje się tak, ponieważ wspomniany wyżej okres wprowadził do modelu większą wrażliwość na zmiany, dzięki czemu przewidywanie stara się tym bardziej imitować oscylacje obecne w prawdziwych danych.

Najlepszym wyborem wydaje się być zestaw 1, obejmujący pełny zakres danych, z wyłączeniem wartości odstających (outlierów), które znajdowały się poza granicą błędu 3σ.

3.1 Dobór parametrów modelu dla Zestawu 1

W kolejnym etapie przeprowadzono analizę wpływu parametrów modelu na jakość predykcji. Dla zestawu danych 1 (pełny zakres danych względnych, oczyszczony z outlierów), model LSTM trenowano dla trzech różnych szerokości okna czasowego: 6, 12 i 24 miesięcy. Dodatkowo analizowano model w trzech przedziałach czasowych:

- pełny zakres danych: od stycznia 1982 do końca 2024 roku,
- ostatnie 10 lat danych,
- ostatnie 5 lat danych.

Dla każdego wariantu obliczono wartości błędów RMSE oraz MAPE. Poniżej przedstawiono wyniki dla wybranych konfiguracji:
Okno: 6
Zakres danych: pełny; ostatnie 5 lat

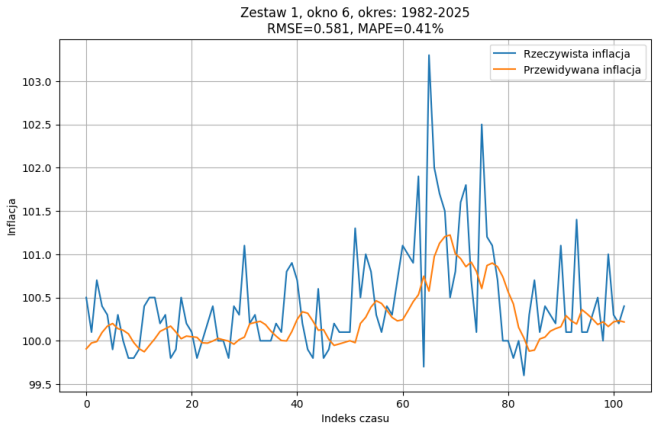

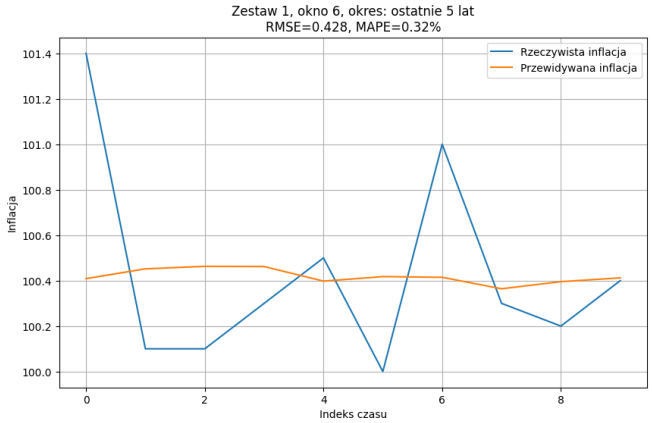

Okno: 12
Zakres danych: pełny; ostatnie 5 lat

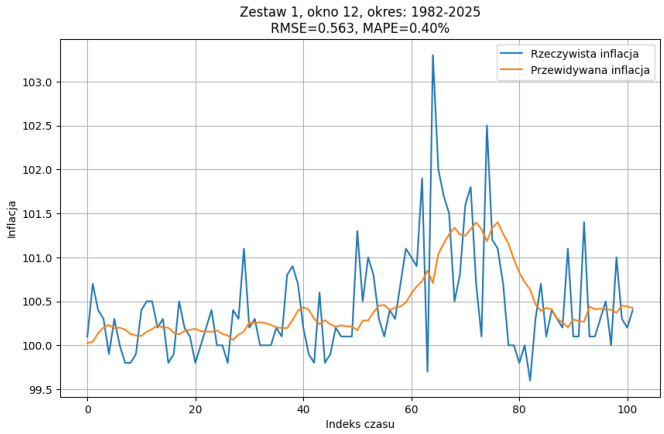

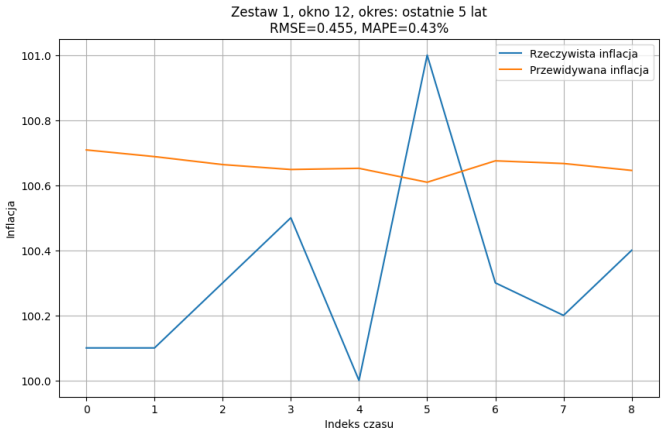

Okno: 24
Zakres danych: pełny; ostatnie 5 lat

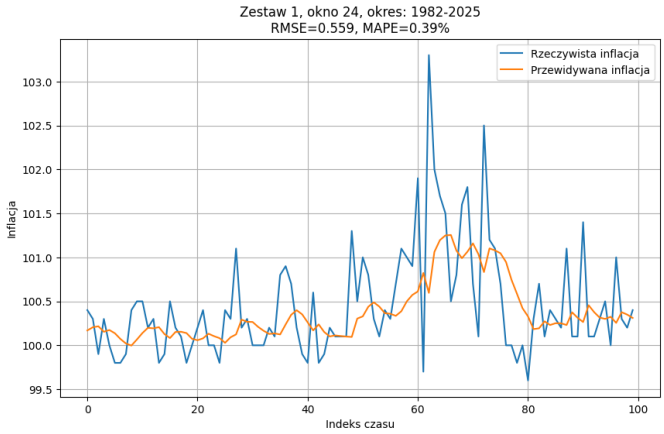

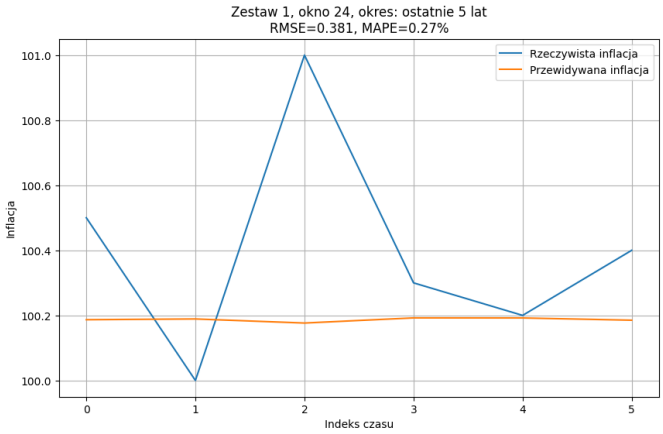

Podsumowanie wpływu szerokości okna i zakresu danych

Analiza błędów RMSE i MAPE dla różnych szerokości okna oraz zakresów czasowych danych wskazuje jednoznacznie, że najlepsze rezultaty predykcji osiągnięto przy zastosowaniu okna o szerokości 24 miesięcy oraz ograniczeniu danych do ostatnich 5 lat.

W tej konfiguracji model osiągnął najniższe wartości zarówno błędu średniokwadratowego (RMSE), jak i średniego błędu procentowego (MAPE), co sugeruje, że:

- dłuższe okno umożliwia modelowi uchwycenie szerszego kontekstu czasowego i sezonowości,
- dane z ostatnich lat są bardziej jednorodne i reprezentatywne dla aktualnych trendów inflacyjnych,
- pominięcie dawnych danych historycznych (np. z okresu transformacji gospodarczej) eliminuje zakłócenia, które mogłyby utrudniać proces uczenia się przez model.

W praktyce oznacza to, że w zastosowaniach operacyjnych — gdzie celem jest trafna prognoza inflacji w krótkim i średnim horyzoncie czasowym — warto korzystać z modelu LSTM trenowanego na danych z ostatnich kilku lat oraz z relatywnie szerokim oknem wejściowym.

4 MLPRegression

MLPRegressor (Multi-Layer Perceptron Regressor) to model regresyjny oparty na sztucznej sieci neuronowej typu MLP (wielowarstwowy perceptron). Jest używany do przewidywania wartości ciągłych, czyli do rozwiązywania problemów regresji, takich jak prognozowanie inflacji w kolejnych miesiącach.

4.1 Ustalenie rozmiaru okna miesięcy poprzedzających

Do nauk modelu używamy poprzedzających miesięcy, do przewidywań wartość inflacji następnym miesiącu. Jednak pojawia się problem, z wyznaczeniem ilości poprzedzających miesięcy. Dlatego na początku przetestowaliśmy 4 różne modele, uczące się przez maksymalnie 2000 iteracji, korzystające z funkcji aktywacji ReLU oraz optymalizatora wag ADAM, składające się z:

1. 260 neuronów w wejściowej warstwie, 150 w warstwie ukrytej i 85 w warstwie wyjściowej.
2. 150 neuronów w wejściowej warstwie, 400 w warstwie ukrytej i 150 w warstwie wyjściowej.
3. 64 neuronów w wejściowej warstwie, 64 w warstwie ukrytej i 64 w warstwie wyjściowej.
4. 250 neuronów w wejściowej warstwie, 250 w warstwie ukrytej i 250 w warstwie wyjściowej.

Sprawdzając przedziały od 2 do 30 miesięcy, każdy model uczyliśmy 10 razy, po czym obliczaliśmy średnią arytmetyczną z wskaźnika MSE.

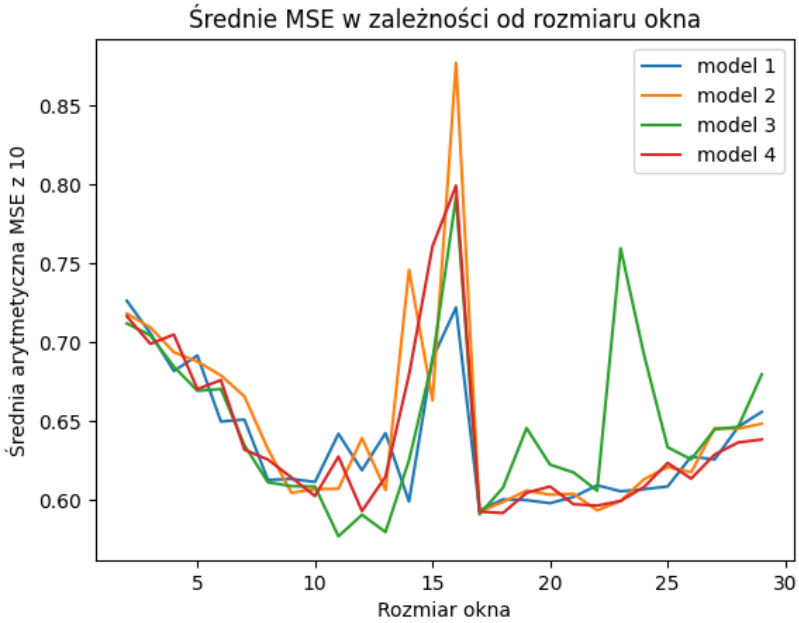

Rys. 6: Wykres średnich wartości MSE poszczególnych modeli w zależności od ilości miesięcy branych pod uwagę, w celu predykcji inflacji następnego miesiąca.

Z wykresu możemy odczytać, że najmniejszą wartość MSE otrzymywaliśmy, ucząc modele biorąc 11 poprzednich miesięcy. Najmniejsze wartości otrzymywaliśmy dla 9, 10, 11, 12 i 17 miesięcy, dlatego w dalszych próbach otrzymania jak najlepszych aproksymacji inflacji, do uczenia będziemy używali 11 miesięcy wstecz.

4.2 Wyznaczanie najlepszych hiperparametrów

Mając już gotowe dane oraz wyznaczony rozmiar okna miesięcy, przystępujemy do wyznaczania hiperparametrów. Ręczna analiza, zajęła by zbyt wiele czasu, dlatego posłużyliśmy się Optuną, automatycznym framework'iem do optymalizacji hiperparametrów. Ograniczymy się również do sprawdzenia różnych przypadków modeli, mających 3 warstwy neuronów. Sprawdzimy model dla 500 różnych permutacji parametrów:

- ilość neuronów dla warstwy wejściowej: od 10 do 500,
- ilość neuronów dla warstwy ukrytej: od 25 do 2000,
- ilość neuronów dla warstwy wyjściowej: od 10 do 500,
- funkcji aktywacji: identity, ReLU,
- maksymalnej ilości iteracji: od 2000 do 4000
- harmonogramu tempa nauki dla aktualizacji wag: od 0.0001 do 0.1 (także w celu przyśpieszenia uczenia)

Uczenie tak dużej ilości modeli, zajmuje nam około 4 godzin. Wykorzystajmy hiperparametry modelu, którego wskaźnik MSE jest najmniejszy.

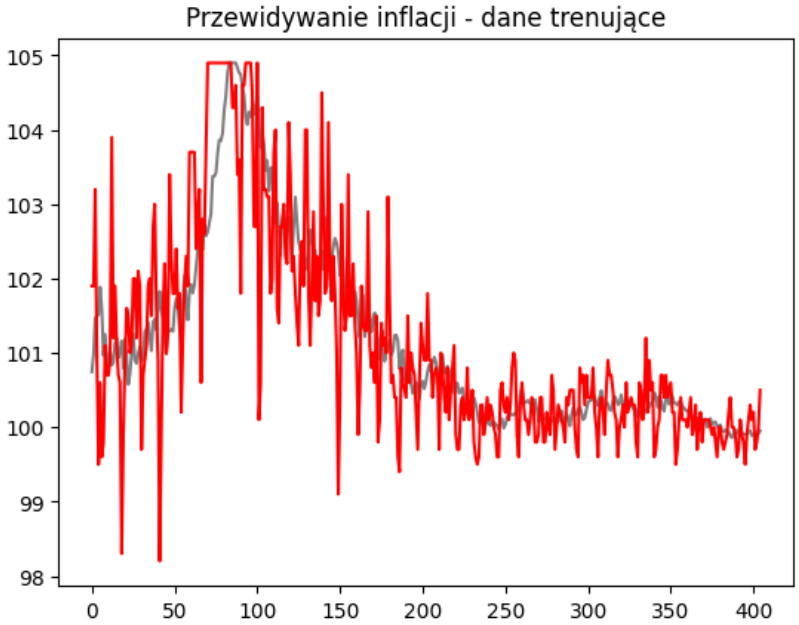

Rys. 7: Wykres prawdziwej inflacji danych uczących oraz wyniki predykcji. Oś x oznacza kolejne miesiące, zaczynając od stycznia 1982 roku, a oś Y procent inflacji.

- Współczynnik determinacji danych trenujących (R^2): 0.6807
  Wskazuje to na umiarkowanie dobrą jakość dopasowania, model nie jest ani słaby, ani idealny.
- Mean Absolute Error na danych treningowych: 0.5507
- MSE na danych treningowych: 0.6747
  Niski błąd średnio kwadratowy sugeruje, że duże odchylenia występują rzadko, lub zarówno duże jak i małe odchylenia występują równomiernie.

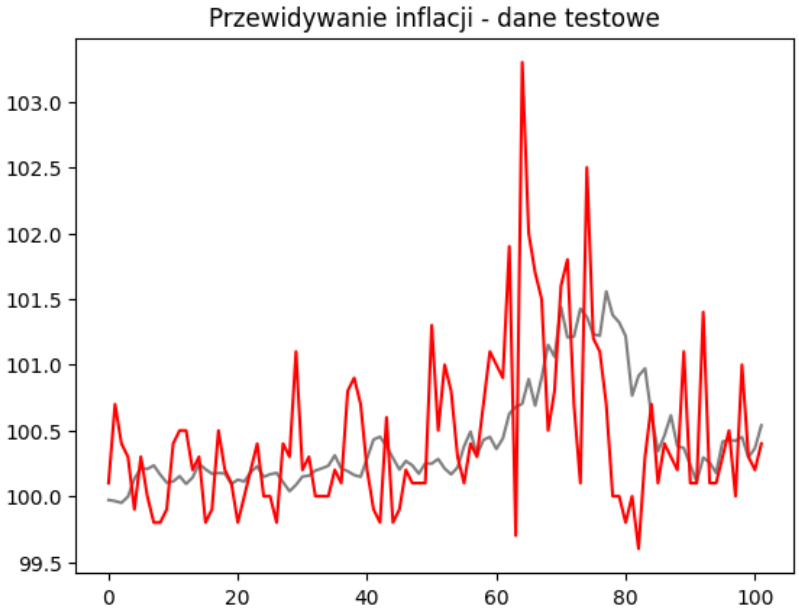

Rys. 8: Wykres prawdziwej inflacji danych testowych oraz wyniki predykcji. Oś X oznacza kolejne miesiące, a oś Y procent inflacji.

- Współczynnik determinacji danych testowych (R^2): 0.0528
  Niestety model wyjaśnia tylko 5,3% wariancji danych, czyli praktycznie nie przewiduje dobrze danych testowych. Może to być spowodowane tym, że wybieraliśmy hiperparametry w zależności od minimalnego MSE, nie uwzględniając wskaźnika R^2.
- Mean Absolute Error na danych testowych: 0.4267
- MSE na danych testowych: 0.3662
  Model otrzymał niższe MSE, dla danych testowych niż dla danych trenujących. Co może sugerować, że dane testowe były prostsze, ponieważ w latach przed 2000 rokiem (czyli latach uwzględnionych w danych trenujących), inflacja miała większe różnice, natomiast w czasie wybranym dla danych testowych, inflacja jest w miarę stabilna.

4.3 Możliwe poprawy

Aby poprawić nasz model MLP, moglibyśmy sprawdzić jego działanie, dla większej ilości neuronów i ich warstw. Sprawdzić również moglibyśmy, czy uczenie na danych od stycznia 1999 roku okazałoby się lepszym sposobem, gdyż od tego miesiąca, został zmieniony sposób obliczania inflacji, czego wynikiem były stabilniejsze zmiany wzrostu inflacji.

Link do repozytorium projektu

https://github.com/Krzemon/Inflation-Forecasting